

ACP 备考资料包

阿里云大模型高级工程师 ACP 认证

六大模块刷题清单 + 2026 模拟卷

考试形式：单选 50 题（每题 1 分）+ 多选 25 题（每题 2 分）

及格分数：80 分（满分 100 分）

考试时长：120 分钟 · 线下机考

本资料版本：2026 版（覆盖蒸馏 / Qwen Code / 上下文工程 / 可观测性等新考点）

第一部分 · 六大模块刷题清单

使用说明：阅读每个知识点后在左侧方框打勾；标注 **2026 新考点** 的条目为 2025 下半年~2026 年课程更新内容，考试权重正在上升，重点复习。清单来源：官方 GitHub 课后小测 + 官方《发布记录》样题 + 掘金分章回忆题。

① 大模型应用开发 17%

- ☐ OpenAI 兼容接口初始化：base_url 指向百炼，使用 DASHSCOPE_API_KEY
- ☐ API Key 安全存储：环境变量 / 配置文件加载，禁止明文嵌入代码或上传公开仓库
- ☐ temperature / top_p / max_tokens 对生成随机性和长度的影响
- ☐ 流式输出 stream=True；批量生成的使用场景
- ☐ 消息角色 system / user / assistant 的职责区分与多轮对话历史管理

② 大模型提示词工程 15%

- ☐ 提示词要素：任务目标 / 上下文 / 角色 / 输出格式 / 样例 (Sample)
- ☐ 分隔符与标识符：###、`【】`、`<< >>` 标识关键要素；`===`、`---`、XML 标签分隔段落
- ☐ Few-shot 示例的作用；意图识别的两种方法（提示词设计 vs 模型微调）
- ☐ 何时直连大模型而非走 RAG 链路（如语法纠错、通用问答）
- ☐ 思维链 CoT / 思维树 ToT / 思维图 GoT 的关系与区别
- ☐ Meta Prompting：用大模型系统性迭代优化提示词 **2026 新考点**
- ☐ 上下文工程 (Context Engineering)：统筹 RAG / Prompt / Tool / Memory 的方法论框架 **2026 新考点**

③ 大模型检索增强 RAG 20%

- ☐ LlamaIndex 使用：SimpleDirectoryReader('./docs').load_data() 加载文档
- ☐ 索引持久化：index.storage_context.persist("路径")
- ☐ RAG 核心流程：文件解析 → 文本切片 → 段落召回 → 段落重排序 → 生成
- ☐ 召回优化：句子窗口检索、自动合并检索、召回片段数 K 的权衡、相似度阈值过滤
- ☐ 实战优化：文本解析质量、标题改写、表格内容增强、分割方法对比、开启拒识

- ☐ RAGAS 指标体系与 RAG 自动化评测；上下文是 RAG 的生命线
- ☐ 意图空间与知识空间；RAG 优化三方向：知识工程 / 评测系统 / 工程与算法优化 2026 新考点

④ 大模型微调 / 蒸馏 16%

- ☐ 微调的作用、适用前提、基本步骤、常用算法（SFT、LoRA 等）
- ☐ 数据集构建：system / user / assistant 结构，标签一致性，质量优于数量
- ☐ 关键超参：学习率（Learning Rate）、批大小（Batch Size）、训练轮数（Epoch）
- ☐ 微调评测指标：Recall / Accuracy / F1 / 人工打标；区分效果指标 vs 效率指标
- ☐ 模型蒸馏：让小模型获得大模型的专业能力；核心从“调参数”转向“迁移能力” 2026 新考点
- ☐ 用 Qwen Code 辅助实现模型蒸馏（2026 版新增章节） 2026 新考点

⑤ 多 Agent 及多模态应用 16%

- ☐ 基于百炼 API 构建智能体；Agent 工作循环：思考 → 行动 → 观察
- ☐ 工具调用（Function Calling / Tool Use）的原理与典型场景
- ☐ Agent 规划与执行；Memory 的长期记忆（外部向量库）vs 短期记忆（上下文）
- ☐ 多 Agent 协作模式：分层规划（规划者-执行者）vs 共创协作
- ☐ Skill：将验证过的能力固化为可复用流程 2026 新考点
- ☐ 评测驱动开发、AgentScope 框架；人机协作 HITL（Human-in-the-Loop） 2026 新考点
- ☐ Qwen Code 终端 AI 智能体实践；多模态交互与行业应用 2026 新考点

⑥ 生产环境应用实践 16%

- ☐ vLLM 高吞吐推理部署；部署选型：百炼 / 函数计算 FC / PAI-EAS / ACS/ACK / ECS
- ☐ 平衡性能与成本：模型路由、缓存复用、合理设置 max_tokens
- ☐ 稳定性：超时重试、降级 fallback、资源弹性伸缩
- ☐ 安全合规：AI 安全护栏产品、Prompt 注入等攻击防护、词库黑名单文本合规检测 2026 新考点
- ☐ 可观测性：Trace 链路追踪 / 日志 / 指标监控——从“能跑通”到“跑得稳” 2026 新考点

资料来源：官方 GitHub 课后小测（V2.1.0+）· 官方《ACP 发布记录》样题 · 掘金「admin皮卡」分章回忆题 · 官方《考纲变更公告》

第二部分 · 2026 版模拟卷

考试说明：共 43 题，总分 55 分。单选题 31 题（每题 1 分），多选题 12 题（每题 2 分，错选不得分）。建议限时 **60 分钟** 完成后再对照答案。带 **2026 新考点** 标注的题目对应本年新增内容，重点关注。

单选题（第 1~31 题，每题 1 分，共 31 分）

模块一 · 大模型应用开发

1. 使用 OpenAI 兼容方式调用百炼平台模型时，`base_url` 应设置为？
A. `https://api.openai.com/v1`
B. `https://dashscope.aliyuncs.com/compatible-mode/v1`
C. `https://bailian.aliyun.com/api`
D. `https://qwen.aliyuncs.com/v1`
2. 关于 API Key 的安全存储，最推荐的做法是？
A. 直接写在代码注释中便于查阅
B. 通过环境变量或配置文件加载
C. 提交到 GitHub 公开仓库做备份
D. 明文嵌入到业务逻辑里
3. 要让模型一边生成一边返回内容（"打字机"效果），需要设置的关键参数是？
A. `stream=False`
B. `stream=True`
C. `top_p=1`
D. `n=2`
4. 生成营销广告文案、需要更多创意多样性时，`temperature` 的合理设置是？
A. 设为 0.0（完全固定）
B. 适当调高（如 0.8）
C. 设为负值
D. 必须保持默认且不可改
5. 设置 `top_p=0.1` 时，模型采样的行为是？
A. 考虑全部候选 Token
B. 仅从累计概率前 10% 的极少数高概率 Token 中采样，输出非常确定
C. 强制输出概率最低的 Token
D. 关闭随机性，与 `temperature` 完全无关

模块二 · 大模型提示词工程

6. 下列符号中，通常用于**分隔段落**（而非标识关键要素）的是？

- A. `[]`
- B. `<< >>`
- C. `===` 或 `---`
- D. `###`

7. 思维树（ToT）和思维图（GoT）是哪一种提示技术的扩展？

- A. 预训练
- B. 微调
- C. 思维链（CoT）
- D. 多模态融合

8. 在意图分类任务中提供若干"输入-标签"示例，这种方法称为？

- A. Zero-shot
- B. Few-shot
- C. 全参数微调
- D. 知识蒸馏

9. **2026 新考点** 关于 **Meta Prompting**，下列描述最准确的是？

- A. 把多张图片拼接成提示词的技术
- B. 利用大模型本身系统性地迭代和优化提示词
- C. 一种压缩 Token 以节省费用的编码方式
- D. 专门用于多 Agent 通信的协议

10. **2026 新考点** "上下文工程（Context Engineering）"的核心思想是？

- A. 只优化提示词模板，不涉及其他组件
- B. 为模型精准地构建并动态管理上下文，统筹 RAG、Prompt、Tool、Memory
- C. 仅指扩大模型的上下文窗口长度
- D. 把所有历史对话无差别全部塞进上下文

模块三 · 大模型检索增强 RAG

11. LlamaIndex 中，将指定文件夹的文档加载为 document 对象的正确写法是？

- A. `SimpleDirectoryReader.load_files()`
- B. `SimpleDirectoryReader('./docs').load_data()`
- C. `read_documents('docs')`
- D. `FileLoader.import_folder('./docs')`

12. 将已构建好的索引持久化到本地的代码是？

- A. `index.save("kb/test")`
- B. `index.storage_context.persist("kb/test")`
- C. `index.export("test")`
- D. `persist_index(index, "test")`

13. RAG 流程中，"Retrieval"阶段主要负责？

- A. 生成最终答案
- B. 从知识库中检索相关内容
- C. 对用户问题做语法纠错
- D. 训练 embedding 模型

14. 召回片段数 K 设置过小，最可能导致的问题是？

- A. 必然触发幻觉
- B. 相关文本切片被遗漏，回答不完整
- C. 模型一定会拒答
- D. 检索速度变慢

15. RAG 回答混入了大量模型自身通用知识、而非严格基于知识库，最直接的优化手段是？

- A. 调高 temperature
- B. 开启"拒识"，仅根据检索到的内容回答
- C. 关闭重排序
- D. 减少 system 提示词长度

16. 专门用于对 RAG 系统做自动化评测的指标体系是？

- A. BLEU
- B. RAGAS
- C. ROUGE-L
- D. Perplexity

模块四 · 大模型微调 / 蒸馏

17. 下列哪种情况最适合采用微调而非仅靠提示词工程？

- A. 偶尔一次的开放闲聊
- B. 需要稳定特定格式/风格输出、且有足量高质量标注数据的专有任务
- C. 临时查询一条实时股价
- D. 一次性的文本翻译

18. 监督微调 (SFT) 的训练数据通常采用哪种结构?

- A. 纯文本无标注
- B. 包含 system / user / assistant 角色的消息对
- C. 仅图片
- D. 随机噪声向量

19. **2026 新考点** 2026 版课程将"通过微调提升准确度"升级为"用蒸馏让小模型掌握专业能力", 其核心转变是?

- A. 从"迁移能力"转向"调参数"
- B. 从"调参数"转向"迁移能力", 让小模型学到大模型的专业能力
- C. 完全放弃使用小模型
- D. 蒸馏只能用于图像领域模型

20. **2026 新考点** 通义千问团队开源的、可在终端中自主规划并调用工具完成编程任务的 Coding Agent 是?

- A. Qwen Code
- B. Llama Code
- C. GitHub Copilot CLI
- D. Cursor

21. 评测情感分类微调模型时, 下列哪一项**不属于**直接衡量分类效果的指标?

- A. 准确率 Accuracy
- B. 召回率 Recall
- C. F1 分数
- D. 训练耗时 Training Time

模块五 · 多 AGENT 及多模态应用

22. 大模型 Agent 的典型工作循环可概括为?

- A. 编译 → 链接 → 运行
- B. 思考 → 行动 → 观察 (Thought-Action-Observation)
- C. 加载 → 缓存 → 销毁
- D. 加密 → 传输 → 解密

23. 在 Agent 中, "长期记忆"通常存储在哪里?

- A. 模型权重内部
- B. 外部向量数据库 / 文档库
- C. 提示词的固定模板里
- D. 只能放在 GPU 显存

24. **2026 新考点** 把一段经过验证的能力固化为可复用流程供 Agent 反复调用，这一机制是？
- A. Memory
 - B. Skill
 - C. Tokenizer
 - D. Embedding

25. 工具调用（Function Calling / Tool Use）解决的核心问题是？
- A. 让模型拥有更大参数量
 - B. 让模型能调用外部工具/接口以获取实时信息或执行动作
 - C. 降低 API 调用价格
 - D. 替代向量数据库的检索功能

26. **2026 新考点** 将人类决策融入 AI workflow 关键节点、以构建可信 AI 系统的模式称为？
- A. HITL（Human-in-the-Loop，人机协作）
 - B. CI/CD
 - C. A/B Test
 - D. OAuth

模块六 · 生产环境应用实践

27. 在生产环境中进行高吞吐大模型推理部署，常用的推理加速框架是？
- A. vLLM
 - B. Pandas
 - C. Nginx
 - D. Redis
28. 若希望以"事件触发、按量付费、免运维"方式快速发布轻量 AI 助手接口，最契合的云服务是？
- A. 函数计算 FC
 - B. 物理机自建
 - C. 对象存储 OSS
 - D. CDN
29. **2026 新考点** 针对 Prompt 注入、越狱等大模型应用攻击，2026 版课程引入的官方防护产品是？
- A. AI 安全护栏
 - B. 云防火墙
 - C. DDoS 高防
 - D. WAF 网站防火墙

30. **2026 新考点** 2026 版在"生产实践"中新增的可观测性内容，主要覆盖？

- A. Trace、日志、指标监控
- B. 域名解析与备案
- C. 数据库分库分表
- D. 前端埋点与 SEO

31. 关于大模型应用上线后平衡"性能"与"成本"，下列做法**不合理**的是？

- A. 对简单请求路由到更小/更便宜的模型
- B. 无论请求难易一律使用最大模型且关闭所有缓存
- C. 引入缓存复用高频结果
- D. 设置合理的 max_tokens 上限

多选题（第 32~43 题，每题 2 分，错选不得分，共 24 分）

32. 以下参数中，会影响生成结果**随机性**的有？

- A. temperature
- B. top_p
- C. max_tokens
- D. seed

33. 直接把全部私有背景信息一次性塞进提示词，可能导致？

- A. 超过模型上下文长度限制
- B. 处理效率下降、API 成本上升
- C. 关键信息被无关内容稀释，影响准确性
- D. API Key 自动失效

34. 属于提示词设计核心要素的有？

- A. 任务目标（Object）
- B. 上下文（Context）
- C. 输出格式（Output Format）
- D. 模型的参数量

35. 关于 RAG 的召回优化，下列说法正确的有？

- A. 句子窗口检索可在命中句子周围补充更多上下文
- B. 自动合并检索可把相邻小块合并成更完整的大块
- C. 召回片段数 K 越大效果一定越好
- D. 相似度阈值可过滤掉低相关切片

36. 构建高质量微调/评测数据集时，应做到？

- A. 用户输入与模型输出边界清晰
- B. system / user / assistant 角色定义明确
- C. 同类任务风格统一、标签表达一致
- D. 把爬虫乱码、OCR 错码也尽量多塞进去以增大数据量

37. (2026 新考点) 关于模型蒸馏，下列正确的有？

- A. 目标是让小模型获得接近大模型的专业能力
- B. 通常比直接部署超大模型更省成本、更易在生产落地
- C. 可借助 Qwen Code 辅助实现
- D. 蒸馏后小模型一定在所有任务上都优于大模型

38. Agent 工具调用的典型场景包括？

- A. 查询实时天气 / 股价
- B. 调用计算器做精确数值运算
- C. 检索企业内部私有数据库
- D. 直接修改模型的预训练权重

39. 多 Agent 协作常见的组织模式有？

- A. 分层规划（规划者-执行者）
- B. 共创协作（多个角色分工协同）
- C. 单点死循环互相等待
- D. 借助 AgentScope 等框架实现评测闭环

40. 大模型生产部署的可选方案包括？

- A. 阿里云百炼
- B. 函数计算 FC
- C. PAI-EAS
- D. ECS / 容器（ACS、ACK）

41. (2026 新考点) 保障大模型应用安全合规，可采取的手段有？

- A. 接入 AI 安全护栏对输入输出做检测
- B. 基于词库黑名单做文本合规检测
- C. 针对 Prompt 注入等攻击进行防护
- D. 把所有用户输入直接拼入 system 提示词且不做任何过滤

42. (2026 新考点) "上下文工程"统筹的要素包含？

- A. RAG（检索）
- B. Prompt（提示词）
- C. Tool（工具）
- D. Memory（记忆）

43. 提升已上线大模型应用**稳定性**的合理措施有？

- A. 对下游模型/工具调用设置超时与重试
- B. 调用失败时进行降级（fallback）
- C. 通过可观测性（Trace/日志/指标）及时发现异常
- D. 关闭一切监控以节省资源

第三部分 · 答案速查 & 解析

单选题答案速查（第 1~31 题）

1 B	2 B	3 B	4 B	5 B
6 C	7 C	8 B	9 B	10 B
11 B	12 B	13 B	14 B	15 B
16 B	17 B	18 B	19 B	20 A
21 D	22 B	23 B	24 B	25 B
26 A	27 A	28 A	29 A	30 A
31 B				

多选题答案速查（第 32~43 题）

32 ABD	33 ABC	34 ABC	35 ABD	36 ABC
37 ABC	38 ABC	39 ABD	40 ABCD	41 ABC
42 ABCD	43 ABC			

逐题解析

Q1. B

百炼提供 OpenAI 兼容模式，base_url 固定为 `https://dashscope.aliyuncs.com/compatible-mode/v1`，配合 DASHSCOPE_API_KEY 使用。

Q2. B

密钥绝不能明文入代码或上传公开仓库，环境变量/配置文件是基本安全实践。

Q3. B

`stream=True` 开启流式输出，逐 Token 返回，实现"打字机"效果。

Q4. B

创意类文本需要多样性应当调高 temperature；事实问答/抽取类任务则调低（接近 0）以保持稳定。

Q5. B

`top_p`（核采样）只在累计概率达到阈值的最小 Token 集合中采样。`top_p=0.1` 时仅在概率最高、累计到 10% 的极少数 Token 中选择。

Q6. C

官方课程明确区分：`===`、`---` 用于分隔段落；`【】`、`<< >>`、`###`、XML 标签用于标识关键要素。

Q7. C

ToT、GoT 都是思维链 CoT（让模型分步思考）的结构化扩展。

Q8. B

提供示例样本为 Few-shot；不给示例为 Zero-shot；调整权重为微调。

Q9. B

Meta Prompting（V2.1.0，2025年7月引入）：用大模型本身来迭代优化提示词，包括定性指导和基于"参考答案"的自动化迭代。

Q10. B

上下文工程（V2.0.9，2025年7月引入）以统一方法论将 RAG、Prompt、Tool、Memory 整合，本质是"为模型精准构建和动态管理上下文信息"。

Q11. B

标准写法：`SimpleDirectoryReader('./docs').load_data()`，将文件夹内文件加载为 Document 对象。

Q12. B

持久化写法：`index.storage_context.persist("路径")`，官方真题原文即如此。

Q13. B

Retrieval = 检索；Generation 负责基于检索结果生成最终答案。

Q14. B

K 过小会漏掉本应召回的相关切片使答案不完整；K 过大则可能超出上下文长度被截断，官方推荐使用"智能拼装"策略。

Q15. B

开启拒识可约束模型仅基于知识库回答，抑制其调用自身通用知识产生的幻觉。

Q16. B

RAGAS 是 RAG 专用的自动化评测指标体系；BLEU/ROUGE 偏翻译/摘要，Perplexity 偏语言模型困惑度。

Q17. B

微调适合"有足量标注数据 + 需稳定特定输出"的专有任务；实时信息类应走 RAG/工具调用。

Q18. B

SFT 数据采用 system/user/assistant 消息对结构，角色边界需清晰。

Q19. B

2026版（V2.4.2）将重点从"调参数"转向"迁移能力"——蒸馏更贴合工程现实，随大模型能力提升传统微调必要性在下降。

Q20. A

Qwen Code 是通义千问团队开源的终端 AI 智能体，2026 版（V2.4.0）新增其实践章节。

Q21. D

训练耗时是资源/效率指标，不直接衡量分类效果；Accuracy、Recall、F1 才是分类效果评测指标（官方样题原型）。

Q22. B

Agent 核心循环：思考（Thought）→ 行动（Action）→ 观察（Observation），Qwen Code 实践也体现了这一模式。

Q23. B

长期记忆对应系统持久化信息（业务历史、知识库），存于外部向量数据库/文档库；短期记忆在上下文窗口中。

Q24. B

Skill 将验证过的能力固化为可复用流程；Memory 负责记忆存储，两者功能不同。

Q25. B

工具调用让模型能访问外部接口/工具，突破知识边界，获取实时信息或执行外部动作。

Q26. A

HITL（Human-in-the-Loop）：人机协作模式，将人类决策嵌入 workflow 关键节点，构建可信 AI 系统。

Q27. A

vLLM 是生产级高吞吐大模型推理框架，官方课程要求掌握其在阿里云（PAI-EAS/ECS）上的部署。

Q28. A

函数计算 FC：事件驱动、按量付费、免运维，适合快速发布轻量 AI 助手，官方课程明确列为推荐方案。

Q29. A

2026版（V2.0.8，2025年6月）引入阿里云"AI 安全护栏"产品，覆盖多种攻击场景防护。

Q30. A

2026版（V2.4.2）新增可观测性内容：Trace 链路追踪、日志、指标监控，帮助应用从"能跑通"走向"跑得稳"。

Q31. B

一律使用最大模型且关闭缓存会显著推高成本与延迟，不合理；其余均为降本增效的合理手段。

多选题解析

Q32. ABD

temperature、top_p 直接控制随机性；固定 seed 影响可复现性（同 seed 结果一致）。max_tokens 只控制输出长度，不影响随机性，故 C 排除。

Q33. ABC

超长上下文会触及长度限制、拉低效率与推高成本，并稀释关键信息。D 错——API Key 安全与提示词长度无关。

Q34. ABC

任务目标、上下文、输出格式（及角色、样例）是核心要素。模型参数量属于模型特性，不是提示词要素。

Q35. ABD

句子窗口检索、自动合并检索、相似度阈值均为有效优化手段。C 错——K 过大易导致超出上下文长度被截断，并非越大越好。

Q36. ABC

边界清晰、角色明确、风格与标签一致都是高质量数据的要求。D 错——低质乱码数据会使模型学到错误分布，官方课程明确指出这是常见错误。

Q37. ABC

蒸馏让小模型获得专业能力、更省成本，并可借 Qwen Code 实现。D 错——小模型不可能在所有任务上全面超越大模型，过于绝对。

Q38. ABC

工具调用用于实时数据查询、精确计算、检索私有库等。D 错——工具调用不会修改模型权重，权重修改属于微调范畴。

Q39. ABD

分层规划、共创协作是官方列出的两种协作模式，AgentScope 可实现评测闭环。C 是故障场景，不是协作模式。

Q40. ABCD

百炼、FC、PAI-EAS、ECS/容器（ACS、ACK）均为官方在课程中列出的完整部署方案。

Q41. ABC

安全护栏检测、黑名单合规检测、注入攻击防护均正确。D 错——不过滤直接拼接是安全合规大忌。

Q42. ABCD

上下文工程框架正是统筹 RAG（检索）、Prompt（提示词）、Tool（工具）、Memory（记忆）四个核心要素。

Q43. ABC

超时重试、降级 fallback、可观测性监控都能提升稳定性。D 错——关闭监控会让异常无法被及时发现，与目标相悖。